


Comment le texte arrive au modèle ?

Des caractères aux tokens,
des tokens aux vecteurs.

Trois opérations se suivent et ne se confondent pas pour rendre le langage compréhensible par la machine.





Encoder les caractères conserve le texte ; attribuer des identifiants permet de le retrouver ; produire des vecteurs permet d'effectuer des calculs.

01. Du texte aux tokens

Le texte est découpé en unités appelées tokens.
Un token n'est pas toujours un mot. Les mots fréquents forment un token unique, les mots rares sont fragmentés.

[« Manger »]

[« Anti »]

[« constitution »]

[« nnellement »]





Le ticket de vestiaire

Chaque token du vocabulaire porte un numéro arbitraire.
Ce numéro ne dit rien du sens du mot, il dit seulement où aller
chercher. Le numéro 428 ne décrit pas le manteau, il indique le casier.


L'identifiant sert d'adresse dans la matrice.

02. Des tokens aux vecteurs

Le numéro ouvre le casier.
La matrice de plongement
(embedding matrix) contient
une ligne par token.

Ce qu'on y trouve est une liste
de nombres : un objet sur
lequel on peut calculer,
mesurer une distance,
additionner, soustraire.






03. D'où viennent ces nombres ?

Au départ, ils sont tirés au hasard. Chaque erreur de prédiction ajuste légèrement les nombres.

Des tokens apparaissant dans des voisinages comparables finissent par occuper des positions comparables.






La carte des voisinages


Si l'on rassemble toutes les lignes de la matrice, on obtient une carte.
La position absolue importe peu. Ce qui compte est le voisinage : quels tokens sont proches, et selon quelles directions on passe de l'un à l'autre.

04. Ce que la géométrie fait apparaître

Pourquoi parler de géométrie ?
Parce que ces coordonnées permettent de **calculer des distances, des angles et des déplacements**.

La matrice donne les coordonnées.
La carte rassemble les positions.
La géométrie rend leurs relations calculables.





$$\text{roi} - \text{homme} + \text{femme} \approx \text{reine}$$


La méthode du décalage vectoriel. Le déplacement qui mène de « homme » à « femme » ressemble à celui qui mène de « roi » à « reine ».

La relation de genre apparaît comme une direction distribuée dans l'espace.

Régularités grammaticales

Le même mécanisme fait apparaître des régularités.
« Aller » est à « allé » ce que
« prendre » est à « pris ».
Aucune règle de
conjugaison n'a été fournie.

L'analogie illustre une
régularité. Elle ne signifie
pas que le modèle
possède une règle
symbolique explicite.






05. Le vecteur statique est aveugle

Le vecteur extrait de la matrice est la première forme du token. Il est aveugle au contexte. « Avocat » y possède la même position initiale dans un tribunal et dans une salade.





Le passage n'est pas l'arrivée

Le transformeur devra confronter ce vecteur aux autres et le déplacer selon la phrase pour fabriquer une représentation contextuelle unique.

La matrice donne au token son point de départ. Le contexte décidera de la trajectoire.