


A

Comment le texte arrive au modèle ?

L'observation d'une métamorphose :
des caractères aux plongements vectoriels.


Trois opérations successives qui ne se confondent pas.

CARACTÈRES	TOKENS	PLONGEMENTS
Le texte devient stockable. (Permet de conserver le texte brut)	Le texte devient indexable. (Permet d'attribuer des identifiants et de retrouver les unités)	Le texte devient calculable. (Permet de transformer les mots en vecteurs pour effectuer des opérations mathématiques)




Le fractionnement : les mots rares se brisent, les mots fréquents résistent.

Le texte est d'abord découpé en unités appelées *tokens*. Un *token* n'est pas toujours un mot entier.




L'identifiant arbitraire n'est qu'un ticket de vestiaire.

Chaque token porte un numéro qui ne dit absolument rien de son sens.
Le numéro 428 ne décrit pas le manteau, il indique simplement où se trouve le casier.




L'ouverture du casier révèle un objet calculable.

L'identifiant sert d'adresse dans la matrice de plongement. On y extrait une liste de nombres : le **vecteur**.




La géométrie se forge par la répétition des erreurs.

Les vecteurs ne proviennent d'aucun dictionnaire.
Ils sont initialisés au hasard et sculptés par l'entraînement.




Le voisinage remplace la définition.

« Chien » et « chat » se rapprochent dans cet espace mathématique car on les rencontre dans les mêmes phrases, non parce qu'une règle les a déclarés comme animaux. Ce qui compte, c'est la position relative.



La méthode du décalage vectoriel calcule le sens.


Aucune colonne du tableau ne s'appelle « genre ». La relation apparaît comme une direction géométrique distribuée dans l'espace.



$$\text{roi} - \text{homme} + \text{femme} \approx \text{reine}$$


La grammaire est aussi une trajectoire spatiale.

Le système n'a reçu aucune règle de conjugaison. L'observation des suites de mots fait émerger des régularités géométriques parfaites entre l'infinitif et le participe passé.



La cécité du vecteur statique

Le vecteur extrait de la matrice est la première forme du token, mais il est aveugle au contexte. Le mot « Avocat » possède exactement la même position initiale, qu'il se trouve dans un tribunal ou dans une salade.



« consulter un avocat » → même vecteur initial

« couper un avocat » → même vecteur initial

La matrice donne le départ, le contexte décide de la trajectoire.

Le plongeant extrait est initial et stable. C'est le transformeur qui, en confrontant ce vecteur aux autres mots de la phrase, fabrique une représentation contextuelle unique à chaque occurrence.

Le passage par la matrice n'est pas la ligne d'arrivée.

