

L'agent naïf : apprendre en enseignant à une IA qui ne comprend pas — fondements théoriques et enjeux de conception d'un cas d'usage du dispositif AnSu

Auteurs : Équipe du dispositif AnSu (Assistant Numérique SUPervisé), DRANE PACA, en incubation à la DNE — contribution de Jean-Baptiste Civet (IAIPR).

Statut du document. Cet article est un *position paper* (perspective théorique). Il mobilise la littérature en sciences de l'éducation et en IA pour l'éducation afin d'établir les fondements scientifiques du cas d'usage « Agent naïf » et d'en justifier les choix de conception. Il ne rapporte pas de résultats empiriques propres à AnSu : il s'agit d'un travail de cadrage théorique préalable à une validation expérimentale, dont les conditions sont discutées en section 6. La littérature mobilisée a été réunie par recherches ciblées (bases arXiv et recherche web, juin 2026), documentées dans `synthese-thematique.md` et `validation-choix-agent-naif.md` ; il ne s'agit pas d'une revue systématique, limite méthodologique assumée du genre.

Version 2 (juillet 2026). Cette version corrige deux attributions (Fiorella et Mayer, 2015 ; catégories direct/indirect de Kobayashi, 2019a), circonscrit la portée du gain chiffré du cadre ICAP, intègre des résultats expérimentaux récents (Xiao et al., 2026 ; Chen et al., 2024), justifie explicitement le choix du bridage par prompt face au désapprentissage ciblé (section 4.3), reprend en points de vigilance les deux angles morts documentés par la `note-critique-agent-naif.md` (section 5), opérationnalise les axes de validation (section 6), et documente en section 5 le calibrage de l'asymétrie d'âge du persona. La version 1 est conservée dans `article-scientifique-agent-naif.md`.

Mots-clés : agent naïf ; IA générative ; effet protégé ; apprentissage par l'enseignement ; cadre ICAP ; paradoxe de la compétence ; ingénierie de prompt ; AnSu.

Résumé

L'usage spontané d'un modèle de langage en classe place l'élève en position d'aidé : l'IA produit une réponse que l'élève reçoit. Cet article examine un renversement de cette relation, le cas d'usage « Agent naïf » du dispositif AnSu, dans lequel l'élève enseigne à un agent conversationnel qui ne comprend pas. Nous montrons que ce renversement active un mécanisme d'apprentissage parmi les mieux établis de la recherche en éducation, l'*effet protégé* (Chase et al., 2009), et est susceptible de déplacer l'élève vers les postures constructive, voire interactive, du cadre ICAP (Chi et Wylie, 2014). Nous identifions ensuite un obstacle spécifique aux modèles de langage, le *paradoxe de la compétence* — la tendance d'un agent instruit de jouer la naïveté à dériver vers des explications de niveau expert — et nous situons la réponse apportée par AnSu (une architecture de prompt

contrainte, dont la version 7 fait l'objet d'une description détaillée) parmi les solutions documentées dans la littérature récente, en justifiant ce choix face à l'alternative du désapprentissage ciblé. L'article conclut sur les conditions de réussite, les limites actuelles du raisonnement et les besoins de validation empirique, notamment via une expérimentation à venir sur un périmètre d'environ 200 classes, accompagnée par un laboratoire de recherche.

1. Introduction

L'intégration des modèles de langage dans les usages scolaires reproduit, par défaut, un schéma d'aide classique : l'élève pose une question, l'IA y répond, l'élève reçoit la réponse. Ce schéma, qualifié ici d'usage *prothétique*, présente un risque pédagogique documenté : il peut se substituer au travail cognitif de l'élève plutôt que le soutenir (Chi et Wylie, 2014). À l'échelle du champ, ce risque a un nom — la surdépendance —, que les revues empiriques récentes rangent parmi les défis les plus fréquents de l'IA en éducation (Shi et al., 2026 ; section 3.5). Le défi pour des dispositifs comme AnSu n'est donc pas de rendre l'IA plus performante, mais de concevoir des usages dans lesquels l'IA, quelle que soit sa compétence intrinsèque, contraint l'élève à produire l'effort cognitif générateur d'apprentissage.

Le cas d'usage « Agent naïf » répond à cette exigence en inversant la relation d'aide habituelle : l'élève n'est plus celui qui reçoit une explication, mais celui qui doit en produire une, à destination d'un personnage conversationnel qui ne comprend pas le sujet traité. Cet article a deux objectifs. Premièrement, établir l'ancrage théorique de ce renversement dans la littérature sur l'apprentissage par l'enseignement et l'effet protégé. Deuxièmement, expliciter pourquoi cet ancrage théorique, robuste pour des agents à enseigner classiques, ne se transfère pas automatiquement aux agents conversationnels fondés sur des modèles de langage, et montrer comment la conception du prompt d'AnSu répond à cette difficulté.

L'article est organisé comme suit. La section 2 présente le cadre théorique : le modèle ICAP, le mécanisme d'apprentissage par l'enseignement, l'effet protégé, et la distinction entre construction et transmission de connaissances. La section 3 situe le cas d'usage « Agent naïf » dans l'architecture conceptuelle d'AnSu. La section 4 expose le paradoxe de la compétence, obstacle propre aux modèles de langage, et les solutions documentées dans la littérature récente. La section 5 discute les conditions de réussite et les points de vigilance. La section 6 conclut sur les limites de l'analyse et les perspectives de validation empirique.

La contribution théorique de cet article n'est pas de démontrer que l'apprentissage par l'enseignement favorise l'apprentissage — résultat déjà largement établi (section 2) — mais d'examiner les conditions sous lesquelles ce mécanisme peut être transposé à des agents conversationnels fondés sur des modèles de langage. Nous proposons que la difficulté centrale de cette transposition réside dans le *paradoxe de la compétence*

(section 4), auquel répond une architecture de prompt contrainte (section 3.4). La figure 1 synthétise cet enchaînement argumentatif.

2. Cadre théorique

2.1 Le cadre ICAP : de la réception à la construction

Le cadre ICAP (Chi et Wylie, 2014) distingue quatre modes d'engagement cognitif lors d'une activité d'apprentissage — passif, actif, constructif, interactif — et établit que la profondeur de l'apprentissage croît avec le niveau d'engagement. Dans la première étude rapportée par Chi et Wylie (2014), en science des matériaux, le gain mesuré est de l'ordre de 8 à 10 % à chaque palier franchi ; les études ultérieures confirment la hiérarchie des modes (interactif > constructif > actif > passif) sans nécessairement reproduire cette ampleur chiffrée. Cette hiérarchie dispose en outre d'un premier appui expérimental à grande échelle dans le contexte même de l'IA générative : un essai randomisé contrôlé mené auprès de 979 étudiants d'un cours d'introduction à la programmation, dont les quatre conditions opérationnalisent les modes ICAP appliqués à l'usage d'une IA générative, observe des gains d'apprentissage croissants du mode le moins engageant au plus engageant (Xiao et al., 2026).

L'usage spontané d'un modèle de langage en classe maintient le plus souvent l'élève en mode passif ou actif (réception, reformulation marginale). Les apprentissages durables et transférables, en revanche, exigent un engagement constructif (l'élève génère un raisonnement propre) ou interactif (ce raisonnement est confronté à un interlocuteur qui réagit). Le cadre ICAP fournit ainsi un premier critère de conception : un dispositif pédagogique fondé sur l'IA générative gagne en valeur pédagogique dans la mesure où il déplace l'élève vers les postures constructive, voire interactive, plutôt que de le maintenir en réception. Il faut toutefois noter que le mode *interactive* au sens strict de Chi suppose une véritable co-construction et un enrichissement mutuel entre les interlocuteurs ; un agent naïf qui ne fait que simuler la compréhension n'atteint pleinement ce mode que dans la mesure où ses relances réagissent effectivement au contenu des explications de l'élève, à défaut de quoi le dispositif demeure de l'ordre du constructif.

2.2 Apprendre en enseignant

Le principe selon lequel enseigner produit un bénéfice cognitif pour celui qui enseigne (*learning-by-teaching*) est l'un des résultats les plus anciens et les plus répliqués de la psychologie de l'éducation (Bargh et Schul, 1980 ; Duran, 2017). Préparer puis délivrer une explication impose un traitement génératif (Fiorella et Mayer, 2014, 2016) : sélectionner l'information pertinente, l'organiser en une structure cohérente, et l'intégrer aux connaissances antérieures.

Les tailles d'effet rapportées par la littérature sont substantielles. La recension de Fiorella et Mayer (2015) relève un effet positif dans 17 expériences sur 19, avec une taille d'effet

médiane de $d = 0,71$. La méta-analyse de Kobayashi (2019a), qui synthétise 28 études, précise ce résultat : le bénéfice est plus marqué lorsque l'élève enseigne réellement ($g = 0,56$) que lorsqu'il se contente de préparer un enseignement sans le délivrer ($g = 0,35$). L'attente d'un enseignement direct, en face à face ($g = 0,50$), produit par ailleurs un effet nettement supérieur à celle d'un enseignement indirect, par vidéo ou par écrit ($g = 0,27$) — écart que Kobayashi (2019b) interprète comme un effet de l'interactivité de la situation anticipée ; la configuration la plus favorable, préparer puis enseigner directement, atteint $g = 0,84$. Cette gradation est déterminante pour la conception d'un agent à enseigner conversationnel : c'est l'interactivité de la situation — un interlocuteur qui réagit, questionne et résiste — qui maximise le bénéfice cognitif, non la simple occasion d'expliquer.

2.3 L'effet protégé

Le travail fondateur de Chase, Chin, Oppezzo et Schwartz (2009), à l'origine du terme *effet protégé* (*protégé effect*), compare des élèves utilisant un même logiciel d'agent à enseigner (*Betty's Brain*, Biswas et al., 2005) selon qu'ils croient apprendre pour eux-mêmes ou enseigner à un agent. Les élèves en condition « enseignement » consacrent davantage de temps aux activités d'apprentissage et obtiennent de meilleurs résultats. Trois mécanismes sont identifiés :

- un **effort accru**, l'élève se sentant responsable de la compréhension d'autrui ;
- une **meilleure autorégulation**, l'élève surveillant davantage sa propre compréhension pour pouvoir l'expliquer ;
- une **protection de l'ego**, l'élève acceptant plus facilement de reconnaître une erreur lorsqu'elle est attribuée à l'agent plutôt qu'à lui-même.

Le second de ces mécanismes trouve un prolongement récent avec les agents fondés sur des modèles de langage : dans une étude contrôlée en éducation à la programmation, Chen et al. (2024) observent, outre des gains de connaissances, une amélioration des capacités d'autorégulation (*self-regulated learning*) des élèves qui enseignent à l'agent, qu'ils relient à un sentiment d'auto-efficacité renforcé.

Deux propriétés de l'effet protégé sont particulièrement pertinentes pour un public de collège. D'une part, ces bénéfices sont les plus marqués chez les élèves les plus fragiles. D'autre part, l'effet ne suppose aucune expertise préalable du tuteur : il est documenté comme fort chez les non-experts, l'acte d'enseigner rendant immédiatement visibles les lacunes de sa propre compréhension. Cette double propriété rend l'effet protégé plausiblement transposable à la situation d'un élève de collège enseignant à un agent naïf. Nous posons toutefois ce transfert comme une hypothèse, et non comme un acquis : l'effet protégé a été établi avec des agents symboliques explicites — dont l'élève observe les erreurs réelles — et non avec des agents conversationnels fondés sur des modèles de langage, où l'erreur est simulée. La section 4 montre précisément que ce transfert n'a rien d'automatique.

2.4 De la transmission à la construction : le rôle de la relance

Tous les dispositifs d'enseignement par les pairs ne produisent pas les mêmes gains cognitifs. Roscoe et Chi (2007) montrent que le tuteur bénéficie réellement de la situation lorsqu'il s'engage dans une construction réflexive des connaissances (*knowledge-building* : autosurveillance, mise en relation du nouveau et de l'ancien, élaboration), mais qu'il a tendance, par défaut, à se contenter de transmettre une information toute faite (*knowledge-telling*), modalité qui n'apporte presque aucun bénéfice d'apprentissage. Le facteur qui fait basculer le tuteur du « dire » vers le « construire » est la relance de l'apprenant — en particulier les questions de type « pourquoi » et « comment » (voir aussi Shahriar et Matsuda, 2021, sur l'effet des questions de suivi posées par un agent-tutoré).

Ce résultat constitue le point de conception décisif pour un agent naïf : sa valeur pédagogique ne tient pas au fait qu'il reçoive des explications, mais au fait qu'il les interroge. Un agent qui valide sans relancer n'active rien de plus qu'un exercice de reformulation ; un agent qui demande « pourquoi cela fonctionne-t-il ainsi ? » ou « que se passerait-il si l'on changeait ce paramètre ? » contraint l'élève à expliciter, donc à construire.

3. Le cas d'usage « Agent naïf » dans l'architecture conceptuelle d'AnSu

3.1 Un étayage inversé

L'agent naïf constitue l'antithèse de l'usage prothétique de l'IA : loin de réaliser une tâche à la place de l'élève, il crée une situation où l'élève accomplit davantage de travail cognitif qu'en son absence. Ce dispositif peut être décrit comme un **étayage inversé** : ce n'est plus l'IA qui soutient l'élève dans une tâche au-dessus de ses moyens, mais l'élève qui occupe le rôle du pair le plus avancé de la dyade. La zone proximale de développement (Vygotsky, 1978) et la notion d'étayage qui en a été dérivée (Wood, Bruner et Ross, 1976) restent mobilisées, mais l'élève y tient le rôle haut, celui qui structure et transmet le savoir à un interlocuteur moins avancé.

3.2 Genèse instrumentale et charge cognitive

Dans le cadre de l'approche instrumentale (Rabardel, 1995), l'agent naïf est un artefact qui ne devient instrument d'apprentissage que par l'activité de l'élève. La genèse instrumentale opère ici dans le sens recherché : c'est en se servant de l'agent pour expliquer que l'élève reconceptualise le savoir, et non en déléguant cette conceptualisation à la machine.

Cette mobilisation cognitive doit toutefois être calibrée, mais dans un sens précis qu'il convient de ne pas confondre avec une simple réduction. Pour Tricot (2026), la charge cognitive, dans le domaine des apprentissages, ne doit pas être allégée par principe : elle doit être **optimisée**. L'allègement n'est justifié que lorsque la charge dépasse les ressources cognitives de l'élève ; en deçà de ce seuil, c'est au contraire la production

d'effort cognitif qui permet d'apprendre, et toute réduction de cet effort réduit d'autant l'apprentissage. Tricot (2026) nomme **dette cognitive** le phénomène inverse, documenté par Kosmyna et al. (2025) : lorsqu'un outil d'IA générative réalise la tâche à la place de l'utilisateur, l'allègement de charge qui en résulte ne relève pas de l'optimisation mais du contournement, et « en fournissant beaucoup moins d'efforts cognitifs on apprend moins » (Tricot, 2026). Cette mise en garde n'est pas une condamnation de l'IA générative en bloc : tout usage d'un modèle de langage ne produit pas une dette cognitive, et certains usages améliorent l'apprentissage là où d'autres lui nuisent. Le critère discriminant n'est pas l'outil lui-même mais la répartition de l'effort cognitif — qui, de l'élève ou de la machine, réalise effectivement la tâche d'apprentissage —, ce qui justifie précisément de concevoir un usage tel que l'agent naïf plutôt que de récuser l'IA générative par principe.

Cette distinction fixe le principe de conception de l'agent naïf. L'architecture de prompt ne doit réduire que la **charge extrinsèque**, celle qui ne sert pas l'apprentissage — interface simple, cadrage clair de la tâche, formulation explicite de ce qui est attendu de l'élève —, sans jamais réduire l'effort d'explicitation lui-même, puisque c'est précisément cet effort que le dispositif cherche à provoquer et à maintenir. Un agent naïf qui resterait trop compétent rétablirait, par un autre chemin, l'allègement que Tricot identifie comme délétère : en répondant ou en complétant le raisonnement à la place de l'élève, il produirait une dette cognitive là où l'objectif est l'optimisation de la charge utile. Une étude exploratoire récente en théorie musicale (Jin et al., 2025, prépublication) observe simultanément de meilleurs résultats post-test et une charge cognitive perçue réduite avec un agent à enseigner fondé sur un modèle de langage, résultat encourageant mais qui reste à confirmer hors du domaine étudié.

3.3 L'enseignant dans la boucle

L'efficacité de l'agent naïf suppose un contrat didactique explicite : l'élève doit savoir que l'agent est volontairement ignorant, faute de quoi la fiction pédagogique perd sa fonction. L'enseignant cadre l'activité, choisit le grain de savoir à enseigner, et exploite ensuite les traces d'explicitation produites par l'élève. Cette exigence est cohérente avec le principe de conception « *teacher in the loop* » qui structure l'ensemble du dispositif AnSu : l'IA y est conçue comme un instrument au service d'une intention pédagogique définie par l'enseignant, non comme un substitut autonome de celui-ci.

3.4 Opérationnalisation : le gabarit de prompt v7

Les principes qui précèdent ne restent pas à l'état de cadrage théorique : ils sont opérationnalisés dans un gabarit de prompt versionné, dont la version 7 fait l'objet d'une documentation technique dédiée (gabarit-agent-naif-v7.md et manuel-fonctionnement-agent-naif-v7.md). Le gabarit organise le prompt en cinq blocs balisés — rôle, contexte, objectif, consignes, garde-fous — auxquels s'ajoutent à l'exécution l'historique de la conversation et le dernier message de l'élève.

Trois mécanismes traduisent directement les principes des sections précédentes en règles vérifiables. Premièrement, une **règle d'or** impose à l'agent un test avant chaque réponse :

toute réplique qui apporterait, confirmerait ou annoncerait un savoir correct doit être reformulée, et un **lexique protégé** interdit à l'agent d'employer le premier un terme disciplinaire que l'élève n'a pas lui-même prononcé. Ce double mécanisme est la traduction opérationnelle, au niveau de l'instruction de prompt, de la lutte contre le paradoxe de la compétence (section 4.2) : il relève de la famille des pipelines de prompt restrictifs déjà documentée dans la littérature (Jin et al., 2023 ; section 4.3).

Deuxièmement, le bloc objectif introduit des **points essentiels** — la décomposition du bilan attendu en deux à quatre jalons atomiques et vérifiables — dont la couverture est suivie à chaque tour selon trois états (acquis, en cours, absent), un point n'étant acquis que sur la production propre de l'élève, jamais sur une répétition ou une récitation. Ce mécanisme rend opérationnelle, sous une forme vérifiable tour après tour, la distinction qualitative entre *knowledge-building* et *knowledge-telling* établie par Roscoe et Chi (2007) (section 2.4) : la porte de clôture du dialogue demeure verrouillée tant qu'un seul point reste en cours ou absent.

Troisièmement, la clôture du dialogue n'est jamais laissée à la seule appréciation de l'agent : à l'issue de l'échange, une copie intégrale est transmise à l'enseignant, qui seul valide la réussite. Ce choix de conception découle directement du principe *teacher in the loop* (section 3.3) et d'une limite que l'équipe de conception documente elle-même : le jugement de couverture porté par l'agent sur sa propre conversation est faillible, ce qui justifie de le traiter comme un indicateur destiné à orienter la lecture de l'enseignant, jamais comme une note qui s'y substituerait.

Encadré 1 — Extrait illustratif d'un dialogue conforme au gabarit v7. Notion : le cycle de l'eau ; points essentiels : évaporation, condensation, précipitation.

— *Élève* : L'eau de la mer, avec la chaleur du soleil, elle monte dans le ciel. —

Agent : Elle monte ? Moi, quand je regarde la mer, je ne vois pas l'eau monter.

Comment elle fait ? — *Élève* : Elle se transforme, elle devient invisible, comme de la vapeur. — *Agent* : Ah bon ? Moi je croyais que l'eau d'une flaque disparaissait pour toujours quand elle sèche. C'est pas ça ?

L'agent n'a employé aucun terme du lexique protégé (« évaporation » n'est jamais prononcé avant l'élève), n'a rien validé ni complété, et son idée fausse — exprimée à la première personne — porte sur un élément que l'élève a déjà introduit : trois contraintes du gabarit tenues simultanément.

3.5 Positionnement dans le paysage empirique des LLM en éducation

L'argument développé jusqu'ici est de nature théorique ; il gagne à être situé face à l'état empirique du champ. La revue systématique de Shi et al. (2026), qui applique le protocole PRISMA à 88 études empiriques publiées entre novembre 2022 et mars 2025, fournit ce point de référence. Deux de ses constats cadrent directement le positionnement d'AnSu. D'une part, le champ est fortement concentré : l'enseignement supérieur y représente environ trois quarts des études et l'informatique près de deux cinquièmes, tandis que l'enseignement primaire et secondaire (le segment dit *K-12*) demeure nettement sous-

documenté. Le public visé par AnSu — le collège — se situe donc dans un angle mort empirique du domaine. D'autre part, la revue classe la *surdépendance* parmi les défis les plus fréquemment relevés, au deuxième rang derrière la fiabilité et les hallucinations.

C'est sur ce second point que le cas d'usage agent naïf trouve son argument défensif le plus net. Là où un usage prothétique de l'IA (section 1) expose précisément l'élève à cette surdépendance, l'agent naïf l'inverse par construction : l'élève ne reçoit plus une réponse qu'il lui faudrait valider, il produit l'explication et corrige un interlocuteur qui ne sait pas. La posture critique cesse d'être une consigne morale surajoutée pour devenir la condition même de la tâche, ce qui rejoint la distinction entre optimisation de la charge et dette cognitive établie en section 3.2. Xiao et al. (2026) apportent à ce diagnostic un appui expérimental complémentaire : ils soulignent le risque que les étudiants confondent la réussite de la tâche obtenue avec l'aide de l'IA (*task performance*) et l'apprentissage réel (*learning*). L'agent naïf neutralise cette confusion par construction — il n'existe aucune « bonne réponse de l'IA » à obtenir, puisque l'agent ne sait pas. La revue de Shi et al. (2026) fournit par ailleurs une légitimité de vocabulaire — elle range le *learning-by-teaching* et le *learning-by-asking* parmi les activités génératives que les modèles de langage rendent scalables —, mais il s'agit là d'un appui terminologique, non d'une preuve empirique du dispositif.

Ce positionnement doit toutefois être lu avec les réserves que la revue appelle elle-même. Son parti pris empirique s'accompagne d'un biais de positivité reconnu, de l'absence de méta-analyse formelle et d'une fenêtre temporelle arrêtée à mars 2025 ; surtout, elle mesure le plus souvent des scores immédiats et confond largement impact d'usage et impact pédagogique, là où l'enjeu de l'agent naïf est un apprentissage *durable*. La revue ne valide donc pas l'approche : elle en dessine la place. AnSu se situe précisément à l'intersection des angles morts qu'elle identifie — public collège, dispositif *teacher in the loop*, visée d'apprentissage durable —, place que seule l'expérimentation décrite en section 6 pourra effectivement occuper.

4. Le paradoxe de la compétence : un obstacle spécifique aux modèles de langage

flowchart TD

```
A["Apprentissage par l'enseignement<br/>et effet protégé (sections 2 et 3)"] --> B["Transposition à un<br/>modèle de langage"]
B -- "sans contrainte" --> C["Paradoxe de la compétence : <br/>l'IA explique à la place de l'élève<br/>(section 4.2)"]
C --> D["Perte du bénéfice cognitif<br/>(dette cognitive)"]
B -- "avec le gabarit v7<br/>(sections 3.4 et 4.3)" --> E["Naïveté maintenue,<br/>relances structurées"]
E --> F["Effort d'explicitation préservé"]
```

Figure 1. L'architecture argumentative de l'article. Le mécanisme d'apprentissage par l'enseignement (sections 2 et 3) ne se transfère pas par défaut aux modèles de langage :

sans contrainte, la dérive vers la compétence dissout le bénéfice cognitif (section 4.2) ; l'architecture de prompt contrainte du gabarit v7 (sections 3.4 et 4.3) vise à maintenir la naïveté de l'agent et à préserver l'effort d'explicitation de l'élève.

4.1 Du symbolique au conversationnel

Les agents à enseigner « classiques » (*Betty's Brain*, *SimStudent* ; Biswas et al., 2005) reposaient sur une programmation manuelle des connaissances de l'agent et de ses conceptions erronées plausibles, ce qui en limitait le coût et la transférabilité disciplinaire. L'arrivée des modèles de langage lève cet obstacle sur trois plans : le dialogue se fait en langage naturel (Love et al., 2022), un même modèle peut incarner tour à tour le tuteur, le pair ou le novice (Jeon et al., 2023), et le contenu de l'agent est généré à la volée dans le rôle assigné, sans script préétabli.

4.2 Le paradoxe de la compétence

Ce renouveau introduit cependant un obstacle nouveau, pour lequel nous proposons le terme de **paradoxe de la compétence** — désignation que nous introduisons ici et qui, à notre connaissance, n'est pas établie sous cette forme dans la littérature : un modèle de langage invité à « jouer un rôle de novice » dérive spontanément vers des explications de niveau expert dès que la conversation se complexifie. Le modèle comprend le sujet traité, ce qui lui permet d'anticiper, de compléter ou de corriger le raisonnement de l'élève au lieu de l'interroger. L'élève n'a alors plus besoin d'explicitier quoi que ce soit, et le bénéfice cognitif s'effondre, contredisant le mécanisme même que l'agent naïf cherche à activer (section 2.4).

4.3 Solutions documentées et positionnement d'AnSu

Des travaux exploratoires récents, pour l'essentiel des prépublications, documentent trois familles de réponses à ce paradoxe :

1. un **pipeline de prompt restrictif**, qui bride les connaissances exprimables par l'agent et le force structurellement à poser des questions plutôt qu'à répondre (*TeachYou*, *AlgoBo* ; Jin et al., 2023) ;
2. une **délégation sélective des tâches**, où l'humain conserve la tâche cognitive noble et l'agent ne prend en charge que des fonctions auxiliaires (*HypoCompass* ; Ma et al., 2023) ;
3. des **approches techniques de stabilisation du niveau novice** par désapprentissage ciblé des connaissances expertes du modèle (Song et al., 2026).

C'est dans cette troisième catégorie de problèmes, et en s'inspirant de la première famille de solutions, que se situe la réponse de conception d'AnSu. La posture naïve de l'agent n'y est pas une simple instruction de jeu de rôle (« fais semblant de ne pas savoir »), mais une **architecture de prompt contrainte** — détaillée en section 3.4 — qui vise à maintenir l'agent à un niveau d'ignorance stable au moyen d'une règle d'or testée à chaque tour et

d'un lexique disciplinaire protégé, et qui lui interdit explicitement de résoudre le problème à la place de l'élève.

Ce choix de la première famille doit être justifié face à la troisième, car la littérature qui propose le désapprentissage ciblé en documente précisément la motivation : selon Song et al. (2026), un modèle entraîné sur des données de niveau expert peine à maintenir de façon crédible un persona novice sur la durée d'un dialogue lorsque le bridage ne repose que sur l'instruction. Quatre raisons fondent néanmoins le choix d'AnSu. Le bridage par prompt est d'un coût quasi nul et ne suppose aucun accès aux poids du modèle — condition nécessaire pour un dispositif qui doit rester portable d'un modèle à l'autre. Il est réversible et ajustable par l'enseignant, quand le désapprentissage exige un réentraînement. Sa faille documentée — la dérive vers la compétence — est précisément ce que l'architecture v7 instrumente et que l'expérimentation à venir mesurera (section 6). Enfin, le désapprentissage ciblé, encore décrit comme sous-exploré en éducation (Mayeku et al., 2025), reste une voie exploratoire dont la maturité opérationnelle n'est pas établie ; il constitue en revanche une évolution possible du dispositif si l'expérimentation documentait une dérive persistante malgré les contraintes de prompt. Une comparaison systématique des deux approches est proposée dans le document de validation interne du dispositif (validation-choix-agent-naif.md, §3).

Cette architecture cherche ainsi à transformer un défaut connu des modèles de langage (la dérive vers la compétence) en une solution opérationnelle, reproductible par des enseignants sans expertise technique en ingénierie de prompt ; sa stabilité effective en situation réelle constitue toutefois une hypothèse d'ingénierie qui reste à valider (sections 5 et 6).

5. Discussion : conditions de réussite et points de vigilance

L'argument développé jusqu'ici resterait incomplet sans l'examen de ses limites, qui constituent autant de spécifications de conception pour le déploiement du cas d'usage.

Authenticité de la naïveté. Si l'agent reste trop compétent, il prive l'élève de l'effort qui produit l'apprentissage. Chen et al. (2024) le montrent en contexte de programmation : un agent qui produit du code correct empêche l'élève de s'exercer au diagnostic d'erreur. La posture naïve doit donc être tenue dans la durée de l'échange, et non seulement à son ouverture.

Calibrage de l'asymétrie d'âge. Le choix d'un persona *plus jeune* que l'élève tuteur — plutôt qu'un pair de même niveau — n'est pas un simple ressort narratif : c'est une réponse de conception au paradoxe de la compétence (section 4.2). Le niveau scolaire du personnage fournit une ancre de registre lexical *vérifiable*, qui rend l'ignorance diégétiquement cohérente et les violations détectables ; un persona « de même niveau mais ignorant la notion » constituerait une instruction moins stable pour le modèle et une dérive vers la compétence moins observable. Ce choix sert en outre la protection de l'ego

(section 2.3) — la confusion d'un plus jeune est plausible et non menaçante, quand celle d'un pair du même niveau risquerait de paraître stupide ou de renvoyer à l'élève un doute sur sa propre explication —, matérialise l'asymétrie de l'étayage inversé (section 3.1) et force la paraphrase, dont le point suivant rappelle qu'elle est l'ingrédient actif du dispositif. L'objection symétrique — la notion cible n'est pas maîtrisée au niveau joué par l'agent — décrit la condition recherchée, non un conflit : l'agent n'a jamais à maîtriser ni à valider la notion (règle d'or), seulement à ne pas la nommer le premier (lexique protégé), puisque la notion est précisément enseignée pendant le dialogue. Reste que l'écart doit être calibré : trop grand, il dresse un mur de prérequis et déplace l'effort de l'élève vers de la charge extrinsèque (section 3.2). L'ordre de grandeur retenu — un à deux niveaux en dessous de la classe réelle — est laissé au réglage de l'enseignant, qui connaît les prérequis de la notion.

L'effort de reformulation comme ingrédient actif. Love et al. (2022) établissent que c'est la paraphrase — la formulation par l'élève de ses propres mots — qui produit l'apprentissage, et non la simple interaction avec l'agent. La tâche doit donc obliger l'élève à formuler une explication originale, plutôt qu'à sélectionner une réponse préformée.

Relance plutôt qu'acquiescement. Conformément à Roscoe et Chi (2007), l'agent doit systématiquement questionner pour éviter de cantonner l'élève au mode *knowledge-telling*, peu producteur d'apprentissage (section 2.4). Le seul fait de produire un enseignement ne garantit pas l'effort cognitif : le bénéfice tient à la qualité interactive de la situation (Kobayashi, 2019a) bien plus qu'à la simple occasion d'expliquer. Ce constat, que rejoint la revue empirique du champ (Shi et al., 2026), fait de la conception de la tâche — et non du recours à un agent à enseigner en lui-même — le facteur déterminant.

Calibration et dérive dans les échanges longs. Le maintien d'un niveau stable de naïveté sur la durée d'un échange demeure un point de vigilance technique, à surveiller en particulier dans les conversations longues où la dérive vers la compétence (section 4.2) est la plus probable.

Équité d'accès au canal écrit. Le dispositif repose intégralement sur la lecture et l'écriture : l'élève lit les relances de l'agent et tape ses explications. Pour un élève en difficulté langagière, cette barrière scripturale agit en amont de tout bénéfice et menace précisément le public que l'effet protégé favorise le plus — une transposition langagière de l'effet Matthieu (Stanovich, 1986), par lequel les écarts initiaux se creusent au lieu de se réduire. La transcription écrite d'une explication relève en outre de la charge extrinsèque au sens de la section 3.2 : la réduire ne diminue en rien l'effort d'explicitation. L'ouverture d'un canal oral — reconnaissance vocale en entrée, idéalement synthèse vocale en sortie, en conservant la trace écrite pour l'enseignant — est la réponse de conception proposée ; elle est détaillée dans la note critique complémentaire (note-critique-agent-naïf.md, §2).

Statut de l'erreur simulée. L'agent exprime volontairement des conceptions erronées, alors qu'il est porté par l'institution : sans contrat didactique explicite et *permanent*, cette autorité risque de faire internaliser l'erreur comme un savoir validé — un effet de référence, d'autant plus fort que l'élève est démuné pour détecter l'erreur par lui-même. Trois

réponses de conception sont proposées dans la même note critique (§3) : une signalétique de persona affichée en continu pendant l'échange, une présentation obligatoire du contrat didactique par l'enseignant avant la séance, et l'attribution des propos erronés à un personnage nommé plutôt qu'au dispositif institutionnel.

Convergence avec les limites documentées par l'équipe de conception. Le manuel de fonctionnement du gabarit v7, présenté en section 3.4, anticipe lui-même, indépendamment de la littérature mobilisée ici, plusieurs des points de vigilance qui précèdent : la couverture des points essentiels reste un jugement que l'agent porte sur sa propre conversation, donc faillible, ce qui justifie de réserver la décision de réussite à l'enseignant ; un élève peut chercher à forcer la clôture en récitant plutôt qu'en expliquant, risque que le gabarit limite sans l'éliminer ; enfin, la transcription d'un dialogue conduit par un mineur constitue une donnée personnelle dont la conservation relève d'un arbitrage avec le délégué à la protection des données. Cette convergence entre une analyse fondée sur la littérature et une auto-évaluation technique indépendante renforce la robustesse du diagnostic, sans s'y substituer.

Transférabilité disciplinaire encore exploratoire. La majorité des études disponibles porte sur l'enseignement de la programmation. L'extension à d'autres disciplines, dont les sciences de la vie et de la Terre, est plausible — une preuve de concept existe en théorie musicale (Jin et al., 2025) — mais reste à valider empiriquement, ce que vise l'expérimentation décrite en section 6.

Cadrage enseignant indispensable. Le bénéfice pédagogique du dispositif suppose que l'élève comprenne la fiction didactique sous-jacente, et que l'enseignant exploite effectivement les traces d'explicitation produites par l'activité — sans ce second temps, l'effort de l'élève reste sans suite pédagogique.

6. Conclusion et perspectives de recherche

L'agent naïf n'est pas un artifice ludique : il opérationnalise un des mécanismes les plus robustes de la psychologie de l'éducation, l'apprentissage par l'enseignement couplé à l'effet protégé, dont les tailles d'effet sont solides et particulièrement favorables aux élèves fragiles. Il est susceptible de déplacer l'élève vers le haut de l'échelle ICAP, de la réception vers la construction et, dans les meilleures conditions, l'interaction. Il répond enfin, par la conception du prompt, à un obstacle spécifique et documenté des modèles de langage — le paradoxe de la compétence — qui empêcherait sinon ce bénéfice de se produire « par défaut ». C'est la conjonction de ces deux propriétés, un ancrage théorique solide et une réponse de conception ciblée à un problème technique identifié, qui fonde la légitimité scientifique du cas d'usage.

Cet article reste néanmoins un travail de cadrage théorique : aucune des affirmations qui précèdent n'a été vérifiée empiriquement sur le dispositif AnSu lui-même. Trois axes de validation s'imposent pour la suite des travaux :

- (i) mesurer la stabilité effective du niveau de naïveté de l'agent sur des échanges longs et dans des contextes disciplinaires variés ;
- (ii) évaluer les gains d'apprentissage et la charge cognitive perçue auprès d'élèves de collège, en particulier les plus fragiles, pour lesquels la littérature prédit les bénéfices les plus marqués ;
- (iii) documenter la manière dont les enseignants s'approprient les traces d'explicitation produites par l'activité.

Le gabarit v7 fournit lui-même les instruments d'une partie de ces mesures. La ligne d'état machine-lisible qu'il impose à chaque tour (couverture de chaque point essentiel, statut de la clôture) permet de quantifier, sur un corpus de transcriptions, la proportion de clôtures effectives par rapport aux sorties de secours, la vitesse de couverture des points essentiels et sa variabilité entre notions ; la relecture des transcriptions permet, elle, de dénombrer les violations de la règle d'or — terme protégé employé avant l'élève, savoir apporté, complété ou validé —, opérationnalisant directement l'axe (i). Ces questions définissent le programme d'une expérimentation à venir, dont le périmètre vise environ 200 classes et qui sera accompagnée par un laboratoire de recherche ; ses résultats viendront, à terme, compléter le présent argumentaire d'une validation empirique propre à AnSu. Une telle expérimentation répond en outre à des angles morts que la revue systématique du champ signale comme prioritaires : la sous-documentation de l'enseignement secondaire et le manque d'études longitudinales mesurant un apprentissage durable plutôt que des scores immédiats (Shi et al., 2026).

Formulé comme cadre théorique, l'argument proposé est falsifiable : il serait fragilisé si l'expérimentation décrite ci-dessus établissait l'un des résultats suivants :

- (i) l'absence de gain d'apprentissage de l'agent naïf par rapport à un usage conversationnel classique de l'IA ;
- (ii) l'incapacité du gabarit à maintenir durablement une posture naïve sur des échanges longs et variés ;
- (iii) l'absence d'augmentation des comportements d'explicitation et de relance prédits par le cadre ICAP et l'apprentissage par l'enseignement. Énoncer ces conditions de réfutation ne fragilise pas l'argument : elle en fait des prédictions vérifiables plutôt qu'une simple anticipation favorable. Si la dérive vers la compétence se révélait persistante malgré les contraintes de prompt, la voie du désapprentissage ciblé (section 4.3) constituerait l'alternative de conception à instruire.

Le gabarit de prompt v7 décrit en section 3.4 constitue l'artefact concret sur lequel portera cette expérimentation : c'est sa capacité à tenir, en situation réelle et sur la durée d'un échange, les mécanismes qu'il formalise — règle d'or, points essentiels, clôture validée par l'enseignant — qui permettra de transformer le présent cadrage théorique en résultats empiriques propres à AnSu.

Références

Bargh, J. A. et Schul, Y. (1980). On the cognitive benefits of teaching. *Journal of Educational Psychology*, 72(5), 593-604.

Biswas, G., Leelawong, K., Schwartz, D. et Vye, N. (2005). Learning by teaching: a new agent paradigm for educational software. *Applied Artificial Intelligence*, 19(3-4), 363-392.

Chase, C. C., Chin, D. B., Oppezzo, M. A. et Schwartz, D. L. (2009). Teachable agents and the protégé effect: increasing the effort towards learning. *Journal of Science Education and Technology*, 18(4), 334-352.

Chen, A., Wei, Y., Le, H. et Zhang, Y. (2024). Learning-by-teaching with ChatGPT: the effect of teachable ChatGPT agent on programming education. *arXiv:2412.15226*.

Chi, M. T. H. et Wylie, R. (2014). The ICAP framework: linking cognitive engagement to active learning outcomes. *Educational Psychologist*, 49(4), 219-243.

Duran, D. (2017). Learning-by-teaching: evidence and implications as a pedagogical mechanism. *Innovations in Education and Teaching International*, 54(5), 476-484.

Fiorella, L. et Mayer, R. E. (2014). Role of expectations and explanations in learning by teaching. *Contemporary Educational Psychology*, 39, 75-85.

Fiorella, L. et Mayer, R. E. (2015). *Learning as a generative activity: eight learning strategies that promote understanding*. Cambridge University Press.

Fiorella, L. et Mayer, R. E. (2016). Eight ways to promote generative learning. *Educational Psychology Review*, 28, 717-741.

Jeon, J., Lee, S. et Kim, S. (2023). Exploring the roles of conversational agents in education: an empirical study on prompt-based roleplaying. *Journal of Educational Computing Research*, 61(4), 812-839.

Jin, H., Lee, S., Shin, H. et Kim, J. (2023). Teach AI how to code: using large language models as teachable agents for programming education. *arXiv:2309.14534*.

Jin, L., Lin, B., Hong, M., Zhang, K. et So, H.-J. (2025). Exploring the impact of an LLM-powered teachable agent on learning gains and cognitive load in music education. *arXiv:2504.00636*.

Kobayashi, K. (2019a). Learning by preparing-to-teach and teaching: a meta-analysis. *Japanese Psychological Research*, 61(3), 192-203.

Kobayashi, K. (2019b). Interactivity: a potential determinant of learning by preparing to teach and teaching. *Frontiers in Psychology*, 9, 2755.
<https://doi.org/10.3389/fpsyg.2018.02755>

Kosmyna, N., Hauptmann, E., Yuan, Y. T., Situ, J., Liao, X.-H., Beresnitzky, A. V., Braunstein, I. et Maes, P. (2025). *Your brain on ChatGPT: accumulation of cognitive debt when using an AI assistant for essay writing task* [preprint]. arXiv.
<https://doi.org/10.48550/arXiv.2506.08872>

Love, R., Law, E., Cohen, P. R. et Kulić, D. (2022). Natural language communication with a teachable agent. *arXiv:2203.09016*.

Ma, Q., Shen, H., Koedinger, K. et Wu, T. (2023). How to teach programming in the AI era? Using LLMs as a teachable agent for debugging. *arXiv:2310.05292*.

Mayeku, B., Hummel, S. et Memarmoshrefi, P. (2025). Machine unlearning for responsible and adaptive AI in education. *arXiv:2509.10590*.

Rabardel, P. (1995). *Les hommes et les technologies : approche cognitive des instruments contemporains*. Armand Colin.

Roscoe, R. D. et Chi, M. T. H. (2007). Understanding tutor learning: knowledge-building and knowledge-telling in peer tutors' explanations and questions. *Review of Educational Research*, 77(4), 534-574.

Shahriar, T. et Matsuda, N. (2021). « Can you clarify what you said? »: studying the impact of tutee agents' follow-up questions on tutors' learning. *International Conference on Artificial Intelligence in Education*, Springer.

Shi, Y., Yu, K., Dong, Y. et Chen, F. (2026). Large language models in education: a systematic review of empirical applications, benefits, and challenges. *Computers and Education: Artificial Intelligence*, 10, 100529. <https://doi.org/10.1016/j.caeai.2025.100529>

Song, J., Guo, Z. et Lin, J. (2026). Simulating novice students using machine unlearning and relearning in large language models. *arXiv:2603.26142*.

Stanovich, K. E. (1986). Matthew effects in reading: some consequences of individual differences in the acquisition of literacy. *Reading Research Quarterly*, 21(4), 360-407.

Tricot, A. (2026). Entre délestage et dette cognitive : réguler l'usage de l'IA [entretien]. Dans *Les compétences info-documentaires à l'ère des intelligences artificielles génératives*, Cahiers ÉduNum Documentation, n° 71 (p. 5-10). Direction du numérique pour l'éducation, Ministère de l'Éducation nationale.

Vygotsky, L. S. (1978). *Mind in society: the development of higher psychological processes*. Harvard University Press.

Wood, D., Bruner, J. S. et Ross, G. (1976). The role of tutoring in problem solving. *Journal of Child Psychology and Psychiatry*, 17(2), 89-100.

Xiao, R., Ye, R., Hou, X., Wen, J., Kumar, H., Liut, M. et Stamper, J. (2026). Transforming GenAI policy to prompting instruction: an RCT of scalable prompting interventions in a CS1 course. *arXiv:2602.16033*.