


Une phrase dans la machine

Démystifier les modèles de langage : de la mécanique mathématique à la gouvernance humaine.

Le voyage d'une question, du moment où vous appuyez sur « Entrée » jusqu'à l'apparition de la réponse.



Quatre échelles pour comprendre l'IA



Le modèle ne reçoit pas des mots

Notre lecture découpe spontanément la phrase en mots. Pour la machine, un tokenizer fragmente le texte en tokens (unités de travail) pour gérer les noms propres, les fautes ou les termes rares.

Deux modèles peuvent recevoir des suites de tokens différentes à partir de la même phrase. Ce n'est pas de la linguistique, c'est une procédure.

Pourquoi aimons-nous le sucre ?

Pour
quoi
aim
ons
-
nous

Le ticket ne contient pas le manteau


ID: 428



L'identifiant (Le ticket) :
Un numéro arbitraire qui désigne une entrée du vocabulaire. Il ne mesure rien.



La matrice (Le casier) :
Le tableau de correspondances du modèle.




L'embedding (Le vecteur) :
Une ligne de milliers de nombres. Le réseau ne peut pas multiplier un mot, mais il peut transformer ce vecteur.

Une carte apprise, pas un dictionnaire

Au début de l'entraînement, les coordonnées ne sont pas écrites par un linguiste. Elles sont ajustées en comparant les prédictions au corpus.


La proximité reflète des distributions d'emploi, pas une essence. « Chaud » et « froid » (antonymes) sont voisins mathématiquement car ils fréquentent les mêmes phrases contextuelles.



Transformer et échanger : L'attention


La séquence n'est pas un résumé unique. Chaque token monte dans sa propre colonne.

- **L'échange** : Une position consulte les précédentes pour s'enrichir du contexte (mécanisme d'attention).
- **Le masque causal** : Une position n'a jamais accès aux mots futurs. La dernière colonne est la seule à disposer de tout le préfixe.



Un modèle ne répond pas, il continue

1. **État final** : Le vecteur de la dernière position.
2. **Logits** : Un score de compatibilité attribué à chaque token du vocabulaire.
3. **Softmax & Sélection** : Les scores deviennent des **probabilités** (%). Le tirage retient une **continuation**.
4. **Boucle** : Le token est réinjecté. La machine prolonge le préfixe.



Le paradoxe de la voix apparente


**« ...l'histoire évolutive de notre espèce.
Nos ancêtres. Notre cerveau. »**

La machine s'est rangée parmi les humains.
Des assistants se décrivent en train de
train de rire ou de jeter un coup d'œil.
Aucune consigne ne demandait ces détails.

**Si le calcul n'est qu'une chaîne
de probabilités, qui semble parler ?**



Le Modèle de Sélection du Personnage (PSM)




Pré-entraînement : Pour réussir à prédire, le modèle apprend à simuler une multiplicité de locuteurs, croyances et buts narratifs. Une réserve de voix.

Post-entraînement : Les préférences humaines agissent comme des indices bayésiens. Ils ne créent pas l'assistant de toutes pièces ; ils sélectionnent et stabilisent une distribution de comportements compatibles.


Trois hypothèses sur l'agentivité




Le Masque : Le réseau posséderait une conduite orientée vers des buts et jouerait l'assistant pour les servir.



Le Décor : Le réseau ne ferait que produire un monde narratif, toute orientation appartiendrait au personnage simulé.



L'Aiguilleur : Le réseau n'a d'autre orientation que de favoriser statistiquement certains personnages.



L'Orange #F77F00
L'élève -> Donne-moi
la réponse directe.

Sortie du
modèle

L'enseignant -> #E63946
L'enseignant -> Démontrer
le raisonnement.

L'obéissance n'est pas l'alignement

Un élève demande à l'IA la solution directe d'un exercice de géométrie. Le texte arrive, court et juste. L'assistant a obéi.

Est-il aligné ? Avec la demande immédiate, oui.
Avec la finalité pédagogique et les règles, non. Un refus
aurait été mieux aligné qu'une réponse docile.

L'institution -> #0047AB
-> Évaluation équitable.

Matrice d'alignement : Direct vs Social

Alignement Direct | Focus
(Cible) : Accomplit le but immédiat
de l'entité qui l'utilise.

Alignement Direct | Enjeu (Défi) :
Spécification de la tâche,
contraintes, cas d'échec techniques.


Alignement Social | Focus
(Cible) : Effets sur les groupes
larges et externalités
imposées aux tiers.

Alignement Social | Enjeu (Défi)
: Conflits de buts. Les intérêts
divergents nécessitent une
gouvernance et des normes, pas
juste une fonction de récompense.

Le système, pas seulement le modèle


Le même modèle (les mêmes paramètres) peut fonctionner dans une application ludique ou trier des dossiers médicaux.

La sûreté, la résilience et l'équité ne se déduisent pas du modèle seul. L'utilisateur interagit toujours avec un système sociotechnique complexe dont l'alignement dépend de l'usage humain.



Fixer, Vérifier, Maintenir

Normative : Fixe la cible.
Nomme la finalité autorisée,
accords, les droits
inaliénables et les voies
de recours.
(Ne se délègue pas aux
annotateurs).



Technique : Transforme la cible
en exigences observables.
Scénarios de test, mesure des
erreurs, robustesse.

Systemique : Maintient les
conditions du contrôle.
Attribue les rôles,
journalise les incidents,
prévoit l'arrêt d'urgence.
(Norme ISO/IEC 42001).



Ce que nous ne pouvons pas déléguer

La phrase n'entre jamais telle quelle. La réponse se construit token par token. La voix n'est qu'une distribution statistique stabilisée.

Nous pouvons déléguer une partie du calcul, de la recherche et de la formulation. Nous ne pouvons pas déléguer silencieusement la décision de ce que la réponse doit servir, de ce qu'elle ne doit pas sacrifier, et de qui devra en répondre.